

邱全通 (Quantong Qiu)

苏州大学 软件工程硕士在读 (+86) 181-7408-5884 qtqiu@stu.suda.edu.cn

研究方向：大语言模型 (LLMs)、长上下文理解、高效 Transformer、高效推理

技术栈：PyTorch、vLLM、SGLang、Triton、TileLang

教育背景

苏州大学，软件工程，硕士在读（研二）（导师：李俊涛教授）

2025 - 至今

江西财经大学，软件工程，本科（Rank: 2/374）

2021 - 2025

• 获南京大学软件学院保送录取资格 • 获江西财经大学三好学生标兵（全校仅 10 人）

科研与项目经历

高效模型架构（百度松果基金：面向长文本的动态稀疏注意力机制研究） | 主要负责人

2025 - 至今

- **Elastic Attention**：共同主导提出测试时自适应注意力稀疏机制，实现不同 Attention Head 的动态稀疏率分配，在保证模型精度的同时显著提升推理效率。相比 MoBA (Kimi 团队) 和 InfLLM v2 (面壁智能) 等方法，实现更优的效率-性能权衡。该工作被 Qwen 团队在最新研究中列为 Per-Head Selection 范式代表工作。
- **Flux Attention**：提出 Layer-wise Hybrid Attention 架构，有效改进 Elastic Attention 动态稀疏带来的 Memory Fragmentation 问题，实现 Prefill 与 Decode 阶段统一优化，推理速度最高提升 2.7 $\times$ ；该工作已被 NeurIPS 2026 接收。

高效推理范式（华为云：面向推理加速的资源效用优化关键算法）

2024.11 - 2025.6

- **CaliDrop**：提出 Offline KV Storage + Query-aware Calibration 框架，在极端 KV Cache 压缩下恢复语义信息，相比 SnapKV (Princeton University 团队提出) 长上下文推理准确率最高提升 13.03%。
- **OTT**：提出 Outlier Token Tracing (OTT) 方法，首次发现少量异常 Token 会破坏 KV Cache 量化的统计分布假设，并在解码阶段动态识别与保留异常 Token，显著提升低比特量化精度。在 2-bit KV Cache 量化下全面超越 KIVI (CMU 团队提出) 等主流方法，实现最高 6.4 $\times$ 内存压缩与 2.3 $\times$ 推理吞吐提升。

高效推理引擎部署优化（是石科技 Meta-Infer） | 部署优化实习生 & 小组长

2026 - 至今

- **Meta-Infer**：面向异构加速芯片的企业级高性能大模型推理引擎。参与内核补齐、算子优化与通信重构、并行与容量调优等方向的部署优化工作；在无高速卡间互联的 8 卡 PCIe-Only 环境下，将 DeepSeek-V4.1-Flash 输入吞吐由 1,932 提升至 13,274 tok/s (6.87 $\times$)，并支持 1M 超长上下文。相关成果获 量子位 专题报道。

长序列大模型机制探索与综合评测

2025 - 至今

- **CoRe Heads**：利用多模态大模型注意力矩阵中的“查询聚焦检索”特性，成功定位出主导跨模态核心检索的特定注意力头。该机制为长上下文多模态推理提供了关键的稀疏剪枝路径，通过消除不必要的跨模态冗余计算，在无须重新训练且保持 99% 以上原始性能的前提下，成功实现长上下文推理阶段端到端速度提升 2.0 $\times$ 。
- **LOOM-Scope**：开发了用于全面评估长上下文大语言模型的综合模块。成功集成并测试了多种前沿的推理加速框架 (vLLM, SGLang 及各类推理加速方法)，确保了该评估框架的高通用性与扩展性。
- **LongRM**：深入探究奖励模型 (RM) 在处理长文本输入时的上下文边界问题。通过分析信息流与注意力机制揭示模型的内在局限性，并为后续的模型优化提供了理论与经验见解。

垂直领域大语言模型开发与部署

2025.3 - 2025.8

- **核工业大模型**：主导核工业领域大模型的全生命周期研发。负责收集、合成并处理规模达 100B Tokens 的垂直领域数据；基于 LLaMA-Factory 对 Qwen3-32B 模型进行微调，显著提升领域内准确率；最终使用 vLLM 成功完成模型的推理部署与实际应用落地。

学术成果

* 表示共同第一作者

- **Flux Attention: Context-Aware Hybrid Attention for Efficient LLMs Inference** NeurIPS 2026 (CCF A)
Quantong Qiu, Zhiyi Hong, Yi Yang, Haitian Wang, Kebin Liu, Qingqing Dang, Juntao Li, Min Zhang
- **Elastic Attention: Test-time Adaptive Sparsity Ratios for Efficient Transformers** ICML 2026 Main (CCF A)
Zecheng Tang*, Quantong Qiu*, Yi Yang, Zhiyi Hong, Haiya Xiang, Kebin Liu, Qingqing Dang, Juntao Li, Min Zhang
- **MMLongEmbed: Benchmarking Multimodal Embedding Models in Long-Context Scenarios** EMNLP 2026 Main (CCF B)
Haitian Wang, Ruoxi Sun, Quantong Qiu, Juntao Li, Junhui Li, Hua Chen, Jinxiong Chang, Min Zhang
- **OTT: Accurate KV Cache Quantization with Outlier Tokens Tracing** ACL 2025 Long (CCF A)
Yi Su*, Yuechi Zhou*, Quantong Qiu, Juntao Li, Qingrong Xia, Ping Li, Xinyu Duan, Zhefeng Wang, Min Zhang
- **Mechanistic Insights into Functional Sparsity in Multimodal LLMs via CoRe Heads** Preprint
Ruoxi Sun, Quantong Qiu, Juntao Li, Zecheng Tang, Yihang Lou, Min Zhang
- **Recovering Semantic Loss in Extreme KV Cache Compression via Query-Based Calibration** Preprint
Quantong Qiu, Yi Su, Yuechi Zhou, Qingrong Xia, Ping Li, Xinyu Duan, Zhefeng Wang, Juntao Li, Min Zhang
- **LOOM-Scope: A Comprehensive and Efficient Long-Context Model Evaluation Framework** Preprint
Zecheng Tang, Haitian Wang, Quantong Qiu, Baibei Ji, Ruoxi Sun, Keyan Zhou, Juntao Li, Min Zhang
- **LongRM: Revealing and Unlocking the Context Boundary of Reward Modeling** Preprint
Zecheng Tang*, Baibei Ji*, Quantong Qiu, Haitian Wang, Xiaobo Liang, Juntao Li, Min Zhang

学术服务

国际学习表征会议 (ICLR 2027)，审稿人

2026